Vision Foundation Model Application

1. Introduction

Vision Foundation Model(VFM)은 많은 영상으로 미리 학습한 모델이다. DINOv3 [1] 같은 모델에 영상을 넣으면 각 영역의 시각적 특성을 담은 feature 벡터를 얻는다. 예시 객체의 벡터와 다른 영상의 벡터를 비교하면 비슷한 객체가 있는 위치를 찾을 수 있다.

분할에는 픽셀마다 객체와 배경을 구분하는 출력이 필요하다. 그러나 ViT는 영상을 patch 단위로 처리한다. Stride가 16이면 512×512 영상에서 약 32×32개의 feature가 나온다. Feature upsampling은 이 거친 표현을 픽셀 단위의 조밀한 feature로 바꾸는 과정이다.

그림 1은 AnyUp [4]의 논문에서 같은 저해상도 feature를 여러 방법으로 확대한 결과다. 영상의 경계와 내부 구조가 방법에 따라 다르게 표현된다. 색은 feature를 PCA로 시각화한 것이며, 분할 mask 자체는 아니다.

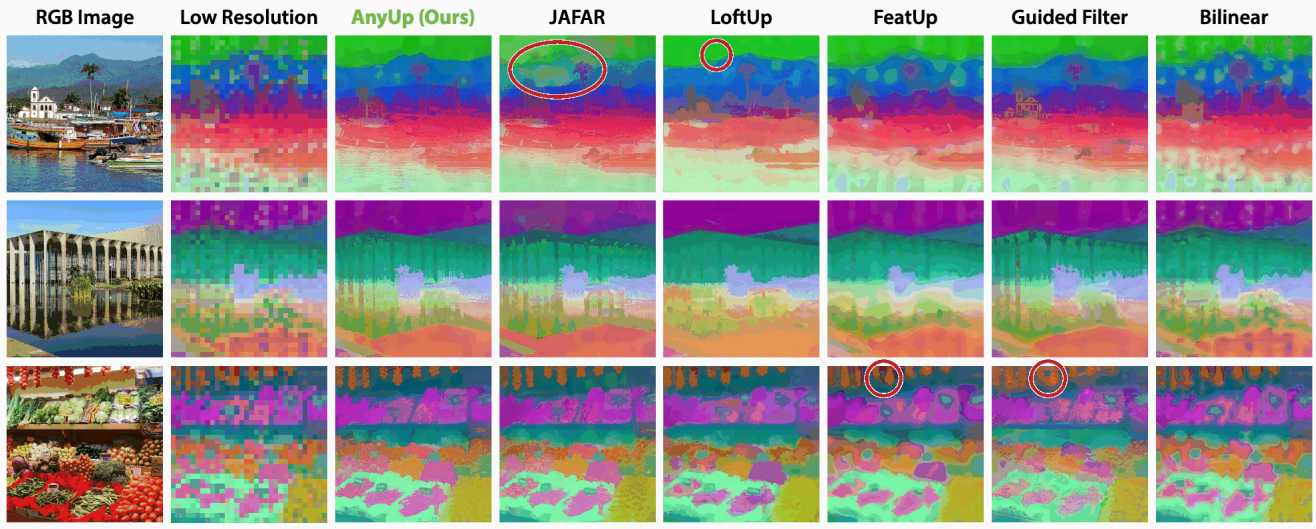


Figure 1. Visual comparison against other methods.

Source: AnyUp [4], ICLR 2026.

입력이나 feature의 해상도를 높이는 목적은 작은 객체를 더 잘 찾고 분할하는 데 있다. 작은 객체는 구분할 단서가 약해 배경으로 처리되기도 한다. Feature grid를 촘촘히 보간하는 것만으로 인식·분할 성능이 좋아지는 것은 아니다. 객체를 확대해 encoder에서 단서를 다시 추출하는 과정과 구분할 필요가 있다.

2. Related Work

FeatUp [2]. RGB 영상을 이용해 저해상도 feature를 영상의 경계에 맞게 확대한다. 두 방식 중 빠른 feedforward 방식은 Joint Bilateral Upsampling(JBU)을 여러 번 적용한다. 한 단계의 핵심은 주변 feature의 가중평균이며, 원문의 JBU를 간단히 정리하면 다음과 같다.

$$
\begin{aligned}
F_{\mathrm{hr},i} &= \sum_{j \in \mathcal{N}(i)} w_{ij} F_{\mathrm{lr},j}, \\
w_{ij} &\propto k_{\mathrm{rgb}}(I_i, I_j)\, k_{\mathrm{pos}}(i,j), \qquad \sum_{j \in \mathcal{N}(i)} w_{ij} = 1.
\end{aligned}
\tag{1}
$$

$F_{\mathrm{lr}} = E(I)$는 encoder의 저해상도 feature이고, $\mathcal{N}(i)$는 위치 i 주변이다. k_{rgb}는 학습된 RGB 표현의 유사도, k_{pos}는 위치 사이의 거리를 반영한다. 따라서 가까우면서 영상의 모습이 비슷한 위치의 feature를 더 많이 가져온다. 서로 다른 해상도의 위치를 맞출 때는 저해상도 feature를 bilinear로 보간한다.

학습할 때는 같은 영상에 작은 이동·확대·좌우 반전을 적용해 여러 feature view를 얻는다. 고해상도 출력을 같은 방식으로 변환하고 다시 줄였을 때 각 view의 encoder 출력과 일치하도록 학습한다. 별도의 고해상도 정답 feature 없이도 확대 규칙을 학습하는 것이다. 다만 추론 시 JBU에 들어가는 의미 정보는 기본적으로 전체 영상에서 한 번 얻은 feature이다.

FeatSharp [3]. 확대 tile을 encoder에 다시 넣어 추가 feature를 얻는다. 영상 일부가 encoder 입력을 크게 차지하므로, 전체 영상에서는 작았던 구조를 더 자세하게 볼 수 있다. 그림 2의 위쪽 경로는 전체 영상의 feature를 FeatUp [2]의 JBU로 확대한 F_0이고, 아래쪽 경로는 tile별 feature를 원래 위치에 이어 붙인 G이다. 주요 경로를 설명용 표기로 정리하면 다음과 같다.

$$
\begin{aligned}
G &= \mathrm{Stitch}(\{E(\mathrm{Resize}(\mathrm{Crop}_r(I)))\}_r)\,, \\
F_{\mathrm{hr}} &= \mathrm{Slice}(T_\psi([F_0; G]))\,.
\end{aligned}
\tag{2}
$$

$[F_0; G]$는 두 feature를 채널 방향으로 붙이는 연산이다. T_ψ는 local attention과 MLP를 적용하는 학습된 transformer block이고, Slice는 출력에서 F_0에 대응하는 채널을 남긴다. 즉, tile의 자세한 정보를 참고해 전체 영상의 확대 feature를 보정한다.

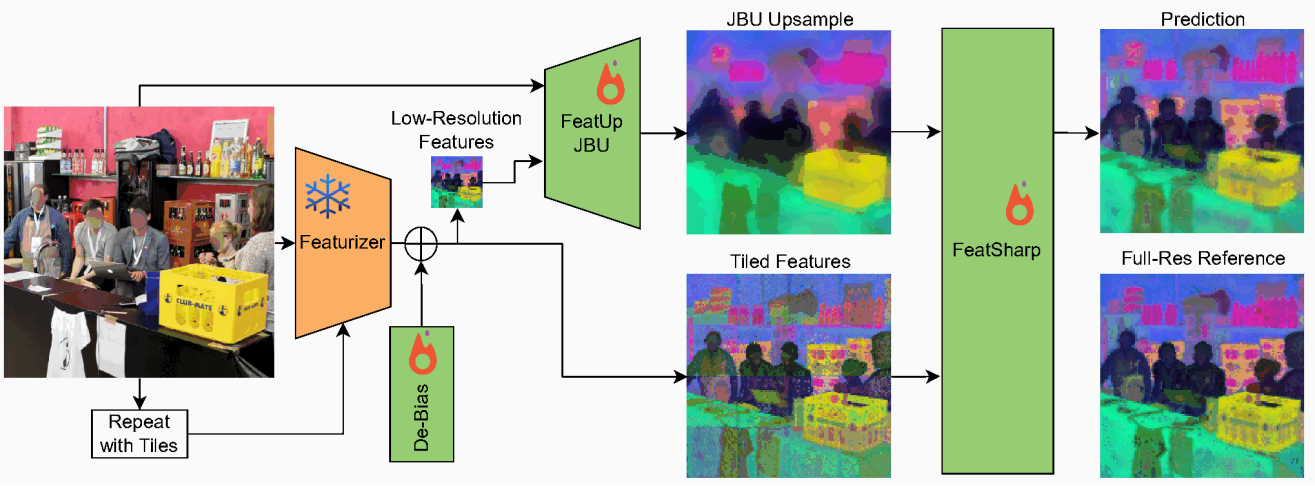


Figure 2. Upsampling architecture diagram.

Source: FeatSharp [3], ICML 2025.

그림 2에서 눈송이가 있는 encoder는 고정하고, 불꽃이 있는 JBU·De-Bias·융합 module은 학습한다. Tile feature에는 세부 구조가 생기지만, 같은 객체도 tile마다 주변 문맥이 달라 경계에서 표현이 끊길 수 있다. 두 경로를 함께 쓰는 이유이다. 오른쪽의 Full-Res Reference는 비교를 위한 시각화이다.

AnyUp [4]. 여러 encoder의 feature를 재학습 없이 확대할 수 있는 attention 구조를 제안했다. 그림 3의 오른쪽에서 RGB 영상은 고해상도 query q_i를 만든다. RGB와 저해상도 feature의 구조 정보는 coarse 위치의 key k_j를 만들고, 원래 feature는 가공하지 않은 value v_j로 들어간다. 이 연산을 일반적인 attention 표기로 쓰면 다음과 같다.

$$
\begin{aligned}
a_{ij} &= \mathrm{softmax}_{j \in \mathcal{N}(i)} \left(\frac{q_i^\top k_j}{\sqrt{d}} \right), \\
F_{\mathrm{hr},i} &= \sum_{j \in \mathcal{N}(i)} a_{ij} v_j, \qquad v_j = F_{\mathrm{lr},j}.
\end{aligned}
\tag{3}
$$

a_{ij}는 픽셀 i에 주변 coarse feature j를 얼마나 사용할지 정하는 비율이다. Window attention은 가까운 위치만 후보로 삼아 멀리 떨어진 영역의 feature가 섞이는 것을 줄인다. RGB는 feature를 가져올 위치를 정하고, 실제 출력 벡터는 원래 encoder의 feature를 가중합해 만든다.

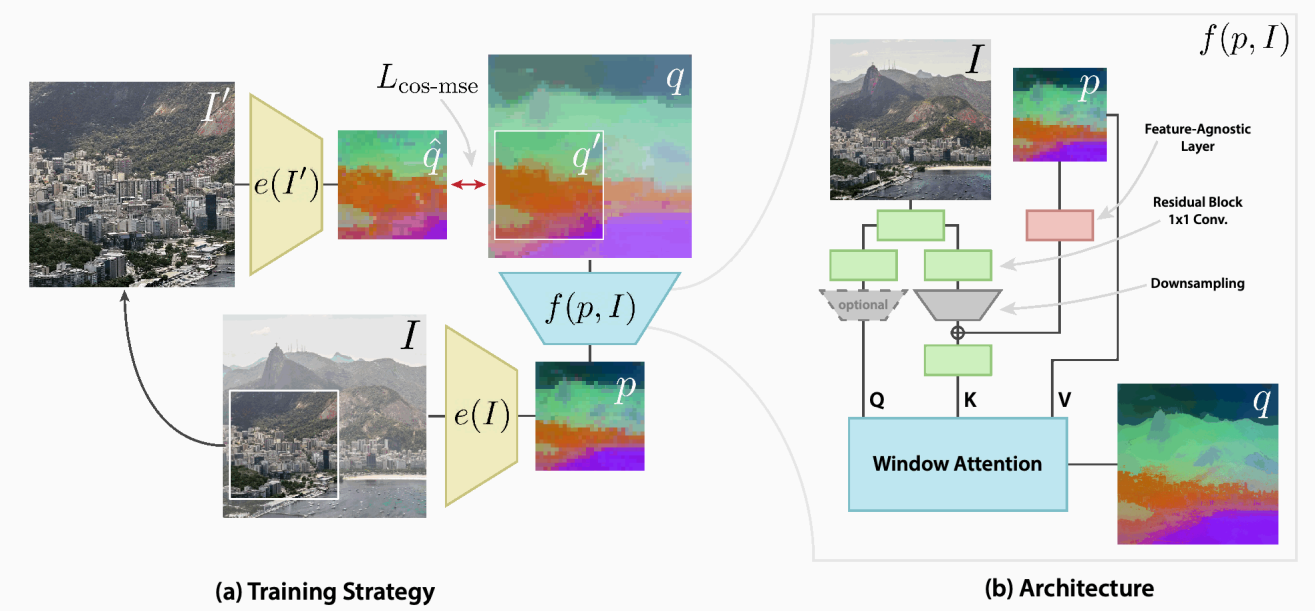


Figure 3. Method Overview.

Source: AnyUp [4], ICLR 2026.

Feature-Agnostic Layer는 각 feature 채널에 같은 필터 집합을 적용하고, 필터별로 정규화한 반응을 채널 전체에서 평균한다. 이렇게 key 경로의 구조 정보를 일정한 차원으로 만들기 때문에 입력 encoder의 feature 차원이 달라도 사용할 수 있다. Value 경로는 원래 차원을 유지한다. 왼쪽의 crop은 학습 목표를 만드는 경로이다. Crop에서 직접 얻은 feature와 확대 출력의 같은 영역을 비교하며 학습하고, 추론 때는 오른쪽의 upsampler를 사용한다.

3. Method

따라서 작은 객체를 더 잘 구분하고 분할하기 위해, 전체 영상과 확대 crop의 feature를 block 평균과 내부 차이로 결합하는 학습 없는 융합을 제안한다. 전체 영상의 평균적인 표현은 유지하고, crop에서 각 위치가 주변과 달라지는 부분을 가져온다.

같은 encoder·layer·upsampler로 전체 영상의 dense feature F_0와 확대 crop의 dense feature G를 얻는다. 영상을 2×2 tile로 나누어 확대하고, 각 tile의 feature를 원래 좌표로 맞춘다. 이때 영상 전체를 덮도록 하여 처음 놓친 객체도 다시 볼 수 있게 한다.

Feature grid를 서로 겹치지 않는 작은 block으로 나눈다. Block은 평균을 계산하는 영역이고, 앞에서 영상을 자른 tile과는 다르다. 픽셀 i가 속한 block을 $B(i)$라고 하면 다음과 같이 결합한다.

$$\hat{F}_i = \underbrace{\bar{F}_{0,B(i)}}_{\text{전체 영상의 block 평균}} + \underbrace{\left(G_i - \bar{G}_{B(i)}\right)}_{\text{crop의 내부 차이}}. \tag{4}$$

$\bar{F}_{0,B(i)}$와 $\bar{G}_{B(i)}$는 block 안의 feature를 채널마다 평균한 벡터이다. Crop의 평균을 전체 영상의 평균으로 바꾸고, crop 내부의 객체–배경 차이는 남긴다. Crop의 문맥 변화 일부를 줄이면서 작은 객체의 대비를 활용하려는 것이다.

이 연산에는 평균·뺄셈·덧셈만 필요하다. 공개 encoder와 upsampler를 고정하고 별도 학습 없이 계산한다. 마지막에는 support mask 안의 평균 feature를 prototype으로 만들고, query feature와 비교해 분할 mask를 얻는다. 이 분할 결과에서 전체 영상의 feature가 놓친 작은 객체를 회복하고 오검출을 줄이는 것이 목표이다.

4. Experiments

COCO-20i와 PASCAL-5i에서 예시 영상과 mask를 1장 또는 5장 제공하고, 다른 영상의 같은 class를 분할한다. 모든 방법에 같은 support/query 영상과 prototype 분할 방식을 사용한다. 전체 영상, crop, 단순 평균, 제안 융합을 비교한다. 아래의 `–`는 아직 측정하지 않은 값이며 benchmark와 shot별로 결과를 기록한다.

방법	비교할 내용	mIoU ↑	작은 객체 회복률 ↑	오검출 ↓
전체 영상 F_0	기존 feature의 분할 성능	-	-	-
Crop G	확대 재추론의 효과	-	-	-
단순 평균 $(F_0 + G)/2$	두 feature를 함께 쓰는 효과	-	-	-
제안 식 (4)	평균과 내부 차이를 나누는 효과	-	-	-

전체 영상과 단순 평균보다 오검출을 늘리지 않으면서 작은 객체 회복률과 mIoU를 높이는 것을 성공 기준으로 삼는다. Feature 시각화가 선명해지는지와 실제 분할이 좋아지는지를 함께 확인한다. 전체 영상과 tile을 추가로 실행하는 추론 시간도 기록한다.

변경 요소	확인할 내용
Block 크기	어느 범위의 평균과 차이를 사용할 때 좋은가
Crop 확대 비율	작은 객체를 크게 보는 정도에 따른 변화
Bilinear / AnyUp [4]	서로 다른 upsampler에서도 융합이 도움이 되는가

References

[1] O. Siméoni et al. *DINOv3*. arXiv, 2025.

[2] S. Fu et al. *FeatUp: A Model-Agnostic Framework for Features at Any Resolution*. ICLR, 2024.

[3] M. Ranzinger et al. *FeatSharp: Your Vision Model Features, Sharper*. ICML, 2025.

[4] T. Wimmer et al. *AnyUp: Universal Feature Upsampling*. ICLR, 2026.

Image Restoration Using Diffusion Prior

1. Introduction

Image restoration은 손상된 영상에서 원본을 추정하는 문제다. 저해상도 영상에서 세부를 복원하는 super-resolution과 흐려진 경계를 복원하는 deblurring이 대표적이다. 그림 1은 I²SB [1]의 두 복원 예시다. 각각 왼쪽부터 입력, 복원 결과, 원본 영상이다.

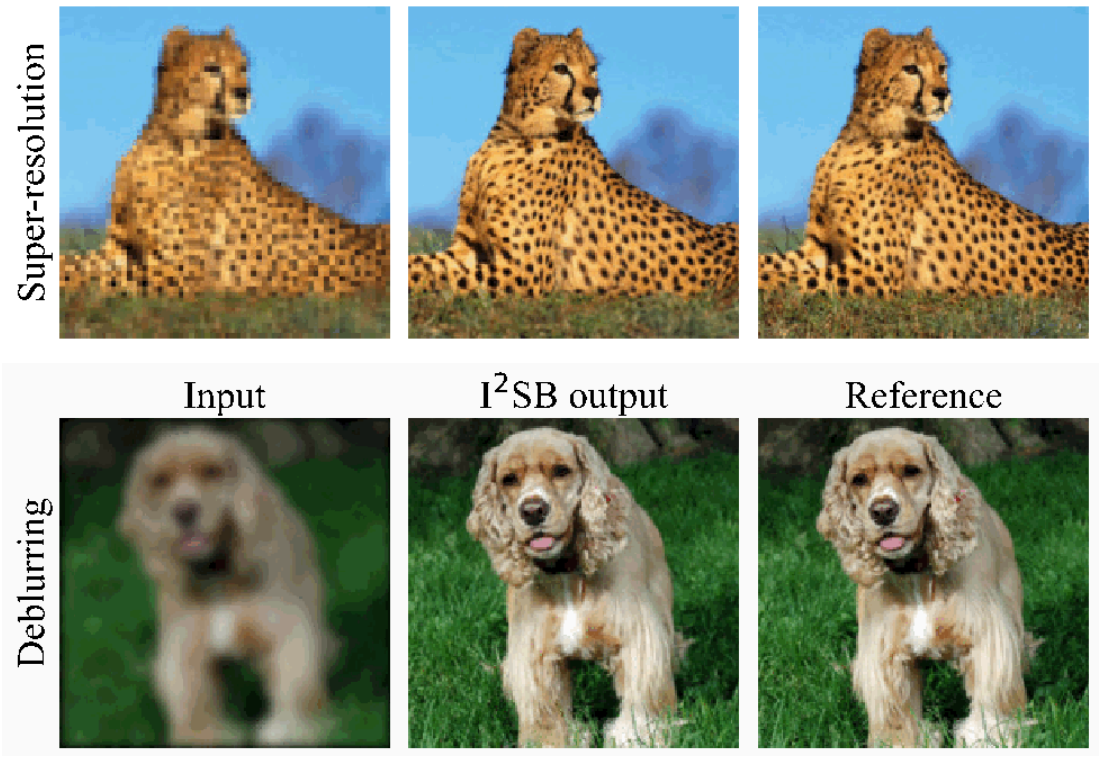


Figure 1. Outputs of our proposed Image-to-Image Schrödinger Bridge (I²SB [1]) on ImageNet 256 × 256 validation set for various image restoration tasks.

Source: I²SB [1], ICML 2023.

원본 x_0에 알려진 열화 연산 A와 잡음 n이 적용되었다면 입력 y는 다음과 같다.

$$y = Ax_0 + n, \qquad n \sim \mathcal{N}(0, \sigma_y^2 I). \tag{1}$$

Super-resolution에서 A는 영상을 줄이는 연산이고, deblurring에서는 blur를 적용하는 연산이다. 같은 입력을 만들 수 있는 원본은 여러 개다. 따라서 입력과 맞으면서도 자연스러운 영상을 찾으려면, 영상에 대해 미리 학습한 정보인 prior가 필요하다.

2. Related Work

Score-Based Diffusion [2]. 깨끗한 영상에 잡음을 더하고, 이를 되돌리는 방향을 학습한다. 여러 방법을 같은 기호로 설명하기 위해 중간 상태와 학습된 score를 다음과 같이 쓴다.

$$x_t = \alpha_t x_0 + \sigma_t \epsilon, \quad \epsilon \sim \mathcal{N}(0, I), \qquad s_\theta(x_t, t) \approx \nabla_{x_t} \log p_t(x_t). \tag{2}$$

α_t, σ_t는 신호와 잡음의 크기다. Score는 현재 상태에서 더 가능성 높은 영상 쪽으로 이동하는 방향이다. 복원에서는 자연스러운 영상을 만드는 것에 더해 관측 y도 만족해야 하므로, 필요한 방향은 다음처럼 나뉜다.

$$\underbrace{\nabla_{x_t} \log p_t(x_t \mid y)}_{\text{복원에 필요한 score}} = \underbrace{\nabla_{x_t} \log p_t(x_t)}_{\text{영상 prior}} + \underbrace{\nabla_{x_t} \log p_t(y \mid x_t)}_{\text{관측 보정}}. \tag{3}$$

첫 항에는 pretrained 모델을 사용할 수 있다. 문제는 둘째 항이다. A는 깨끗한 영상에 적용되는 연산이므로, 잡음이 섞인 x_t를 바로 열화해 관측과 비교할 수는 없다.

DPS [3]. 먼저 x_t에서 깨끗한 영상의 평균을 추정한다. 이 추정치를 다시 열화하고, 관측과의 차이를 줄이는 방향을 구한다. Gaussian 관측에서 보정의 기본 방향은 다음과 같다.

$$\begin{aligned} \hat{m}_t(x_t) &= \frac{x_t + \sigma_t^2 s_\theta(x_t, t)}{\alpha_t}, \\ h_t^{\mathrm{DPS}}(x_t, y) &= -\nabla_{x_t} \frac{\|y - A\hat{m}_t(x_t)\|^2}{2\sigma_y^2}. \end{aligned} \tag{4}$$

첫 줄은 Tweedie의 식으로 얻는 원본 추정이다. 둘째 줄은 이 추정이 입력을 설명하는지 검사한다. Sampling에서는 이 방향에 가중치를 주어 prior score에 더한다. 원본 후보 전체를 다루는 대신 하나의 평균 영상으로 관측 보정을 계산하는 것이다.

TMPD [4]. 원본 후보가 평균 주변에 얼마나 퍼져 있는지도 사용한다. 평균 $\hat{m}_t$와 공분산 $\hat{C}_t$로 원본 후보를 Gaussian으로 근사하면, 관측 쪽의 분포도 계산할 수 있다.

$$\begin{aligned} \hat{C}_t(x_t) &= \frac{\sigma_t^2}{\alpha_t} \nabla_{x_t} \hat{m}_t(x_t), \\ p_t(y \mid x_t) &\approx \mathcal{N}\left(y; A\hat{m}_t(x_t), \sigma_y^2 I + A\hat{C}_t(x_t)A^\top\right). \end{aligned} \tag{5}$$

첫 줄은 추정 평균이 입력 변화에 얼마나 반응하는지로 공분산을 구한다. 정확한 score를 사용하면 조건부 공분산과 같고, 실제로는 학습된 모델로 근사한다. 둘째 줄의 분산에는 관측 잡음과 원본 추정의 불확실성이 함께 들어간다. 공분산을 고정한 채 이 분포의 log-gradient를 구해 식 (3)에 넣는다. 같은 관측 오차라도 불확실성에 따라 보정이 달라지는 것이다.

SIMCA [5]. 관측 보정 방향을 정한 다음, prior와 보정을 얼마나 섞을지 데이터에서 구한다. Diffusion의 경우를 같은 기호로 정리하면 다음과 같다.

$$\begin{aligned} \hat{s}_t(x_t, y) &= a_t s_\theta(x_t, t) + b_t h_t(x_t, y), \\ r_t(x_t, x_0) &= \frac{\alpha_t x_0 - x_t}{\sigma_t^2}, \\ (a_t, b_t) &= \arg\min_{a,b} \mathbb{E}\left[\|a s_\theta + b h_t - r_t\|^2\right]. \end{aligned} \tag{6}$$

h_t는 관측에 맞추는 방향이고, r_t는 계수를 맞추는 기준인 회귀 target이다. 앞 시점에서 실제로 sampling한 상태를 가져와 현재 시점의 두 계수를 구하고, 그 계수로 다음 상태를 만든다. 큰 모델을 다시 학습하는 대신 시점별 두 숫자를 보정하는 방식이다.

이때 target은 관측과 짝지어진 원본 x_0로 만든다. 한편, Gaussian noising에서 정확한 conditional score는 다음 평균으로 표현된다.

$$s_t^\star(x_t, y) = \frac{\alpha_t\, \mathbb{E}[X_0 \mid X_t = x_t, Y = y] - x_t}{\sigma_t^2}. \tag{7}$$

여기서 평균은 관측뿐 아니라 현재 상태 x_t에도 조건화된다. 관측에 맞는 원본 후보가 여러 개라면, 현재 상태에 따라 각 후보의 비중도 달라진다.

3. Method

따라서 현재 sampling 상태에 맞게 원본 후보를 가중하고, 이 평균으로 guidance의 회귀 target을 구성하는 방법을 제안한다. SIMCA [5]의 두 계수 보정은 유지하며 계수를 맞추는 기준을 바꾼다.

관측 y마다 가능한 원본 후보 $u_1, \dots, u_M$을 준비한다. 실제 영상에서는 관측에 조건화된 teacher sampler로 후보를 만든다. 이 후보 묶음을 reference bank라고 한다. 현재 상태 x_t가 주어지면, 각 후보에 잡음을 더했을 때 x_t가 나올 가능성으로 가중치를 구한다.

$$\begin{aligned} \omega_j(x_t) &\propto \exp\!\left(-\frac{\|x_t - \alpha_t u_j\|^2}{2\sigma_t^2}\right), \qquad \sum_j \omega_j = 1, \\ m_{\mathrm{ref}}(x_t, y) &= \sum_j \omega_j(x_t)\, u_j, \\ r_{\mathrm{ref}}(x_t, y, t) &= \frac{\alpha_t\, m_{\mathrm{ref}}(x_t, y) - x_t}{\sigma_t^2}. \end{aligned} \tag{8}$$

현재 상태를 잘 설명하는 후보는 더 큰 비중을 갖는다. 같은 bank라도 상태가 바뀌면 원본 평균이 바뀌는 것이다. 이 평균을 식 (7)에 넣어 만든 r_{ref}로 기존 회귀식의 target을 바꾼다.

$$(a_t, b_t) = \arg\min_{a,b} \mathbb{E}\left[\left\| a s_\theta(x_t, t) + b h_t(x_t, y) - r_{\mathrm{ref}}(x_t, y, t) \right\|^2\right]. \tag{9}$$

Pretrained 모델과 관측 보정 방향은 그대로 사용한다. 사전 보정에서 bank와 현재 상태로 계수를 구한 뒤, 새로운 영상에서는 저장한 계수로 sampling한다. Bank는 사전 보정에만 사용한다.

원격탐사 영상에서는 선명하게 복원하는 것만큼, 밴드별 반사율과 밴드 사이의 관계를 유지하는 것도 중요하다. 특히 이런 물리적 특성을 보존하면서 해상도를 높이거나 흐림을 줄이는 복원을 더 연구하고 싶다. 제안한 보정이 복원 품질을 높이면서 분광 정보도 잘 유지하는지 확인할 계획이다.

4. Experiments

성능 비교는 ImageNet과 FFHQ의 $\times 4$ super-resolution과 deblurring에서 진행할 계획이다. 같은 backbone과 denoiser 호출 횟수(NFE)에서 SIMCA [5]와 제안 방법을 비교한다. PSNR·SSIM·LPIPS로 복원 품질을 보고, 여러 복원 결과의 다양성과 실행 시간도 함께 측정한다. 표의 `-`는 미측정 값이다.

방법	PSNR ↑	SSIM ↑	LPIPS ↓	시간 ↓
SIMCA [5]	-	-	-	-
Bank의 단순 평균을 target으로 사용	-	-	-	-
현재 상태로 가중한 bank target	-	-	-	-

다음 비교로 현재 상태를 반영한 효과와 후보 수의 영향을 확인한다.

Ablation	확인할 내용
Bank의 단순 평균 / 상태별 가중 평균	현재 상태를 반영하면 복원 결과가 좋아지는가
Bank 후보 수 변경	후보가 늘어나면 target의 근사와 품질이 개선되는가
Sampling step 변경	적은 step에서도 이점이 유지되는가

Gaussian mixture에서도 같은 target들을 비교한다. 이 경우에는 정답 분포를 알 수 있어, 복원 후보의 분산과 서로 다른 해의 비율을 직접 비교할 수 있다. 영상 실험에서는 reference 생성과 사전 보정에 걸리는 시간도 기록한다.

이후에는 다중분광 반사율 영상으로 실험을 넓힐 계획이다. 이때는 해당 센서·밴드와 반사율 단위에 맞는 prior와 reference bank를 사용한다. 밴드별 PSNR·SSIM과 함께, 원본과 복원 영상의 픽셀별 밴드 벡터 사이 각도로 분광 형태의 변화를 본다. 복원 결과를 같은 A로 다시 열화한 오차 $\|A\hat{x}_0 - y\|$도 측정해 분광 형태와 관측 일치를 함께 확인한다.

References

[1] G.-H. Liu et al. *I²SB: Image-to-Image Schrödinger Bridge*. ICML, 2023.

[2] Y. Song et al. *Score-Based Generative Modeling through Stochastic Differential Equations*. ICLR, 2021.

[3] H. Chung et al. *Diffusion Posterior Sampling for General Noisy Inverse Problems*. ICLR, 2023.

[4] B. Boys et al. *Tweedie Moment Projected Diffusions for Inverse Problems*. TMLR, 2024.

[5] L. Moroy et al. *Getting Your Guidance Weights Right in diffusion and flow-matching posterior sampling*. arXiv, 2026.

Earth Representation Foundation Model

1. Introduction

Earth representation은 위성영상, 기후, 생태 정보에서 위치의 특징을 배우고, 이를 다른 예측 과제에 사용하는 방법이다. 좌표 기반 표현은 위도·경도를 입력해 특징 벡터를 얻는다. 예를 들어 토양 탄소량을 예측할 때, 조사한 지점의 좌표 특징과 탄소량으로 작은 예측기를 학습하고 다른 위치의 값을 예측한다.

$$z_\theta(c) = f_\theta(c), \qquad \hat{y}(c) = w^\top z_\theta(c).$$

c는 위도·경도, $z_\theta(c)$는 위치의 특징, w는 새 과제에서 학습하는 예측기이다. 좌표 encoder는 관측 자료로 미리 학습하고, 새 과제에서는 고정한 채 소수의 조사 라벨로 w만 학습한다. 관측 정보를 담는 사전학습과 실제 조사 라벨로 값을 예측하는 학습이 나뉘는 구조이다.

2. Related Work

SatCLIP [1]. 같은 위치의 위성영상과 좌표를 한 쌍으로 학습한다. 영상 encoder는 이미지 특징을 만들고, 좌표 encoder는 구면 기저와 주기적인 신경망으로 위치 특징을 만든다. 두 특징이 같은 공간에서 대응하도록 학습한 뒤, 새 과제에서는 좌표 encoder의 출력에 작은 예측기를 붙인다. 그림의 왼쪽은 이 사전학습이고, 오른쪽은 조사 라벨을 사용하는 과정이다.

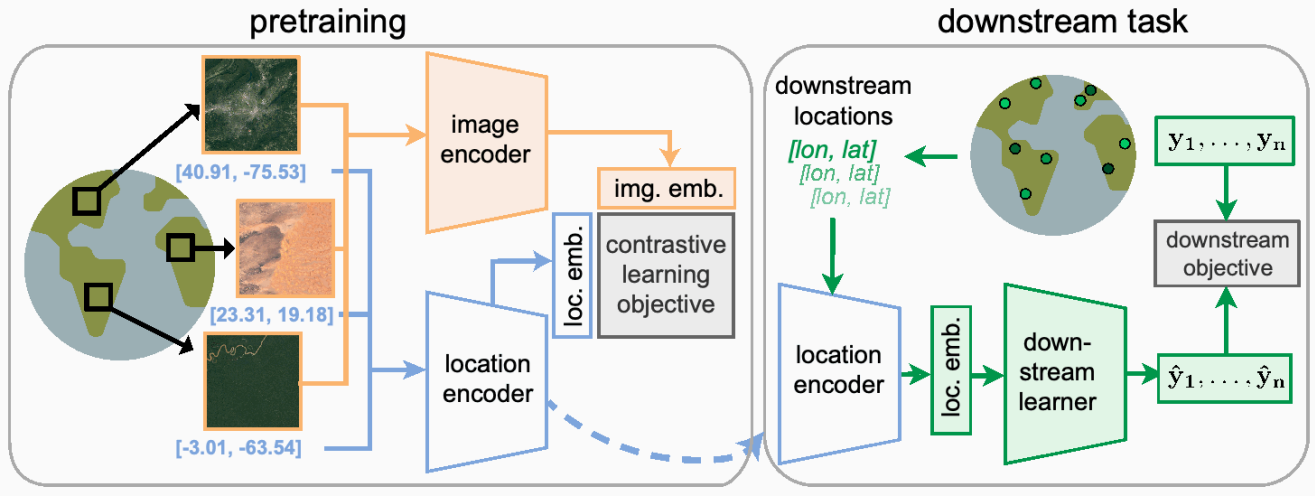


Figure 1. The SatCLIP [1] pretraining and deployment pipeline.

Source: SatCLIP [1], AAAI 2025.

좌표 c_i의 특징을 z_i, 그 위치의 영상 특징을 h_i라 하자. 한 좌표에 맞는 영상을 찾는 방향의 손실은 다음과 같다.

$$\ell_{\text{align}}(i) = -\log \frac{\exp(s(z_i, h_i)/\tau)}{\sum_{j=1}^{N} \exp(s(z_i, h_j)/\tau)}.$$

s는 정규화된 특징의 내적이고, τ는 온도 계수이다. 분자는 같은 위치의 영상과 좌표가 얼마나 비슷한지 나타내고, 분모는 batch의 N개 영상과 비교한다. 영상에서 좌표를 찾는 반대 방향도 함께 학습한다. 이 목표로 위성영상의 정보를 좌표 특징에 담고, 이후 다른 라벨을 예측하는 데 사용한다.

TTE [2]. 좌표를 표현하는 공간 구조도 학습한다. 위도·경도를 단위 구면의 점 x로 바꾸고, 구면에 놓인 여러 site와의 가까움을 계산한다. 각 site에는 위치 s_k와 특징 e_k가 있으며, 두 값 모두 학습된다. 좌표 표현은 다음과 같다.

$$\pi_k(x) = \frac{\exp(\tau_k s_k^\top x)}{\sum_{j=1}^{K} \exp(\tau_j s_j^\top x)}, \qquad v(x) = \sum_{k=1}^{K} \pi_k(x) e_k.$$

K는 site 수, π_k는 그 site의 특징을 섞는 비중이다. s_k와 x는 단위 벡터이므로 내적은 구면에서의 가까움을 나타낸다. $\tau_k > 0$는 각 site의 분할을 얼마나 뚜렷하게 만들지 조절한다. MLP로 처리한 지역 특징과 공유 semantic token을 참고한 특징을 합쳐 최종 좌표 특징을 만든다.

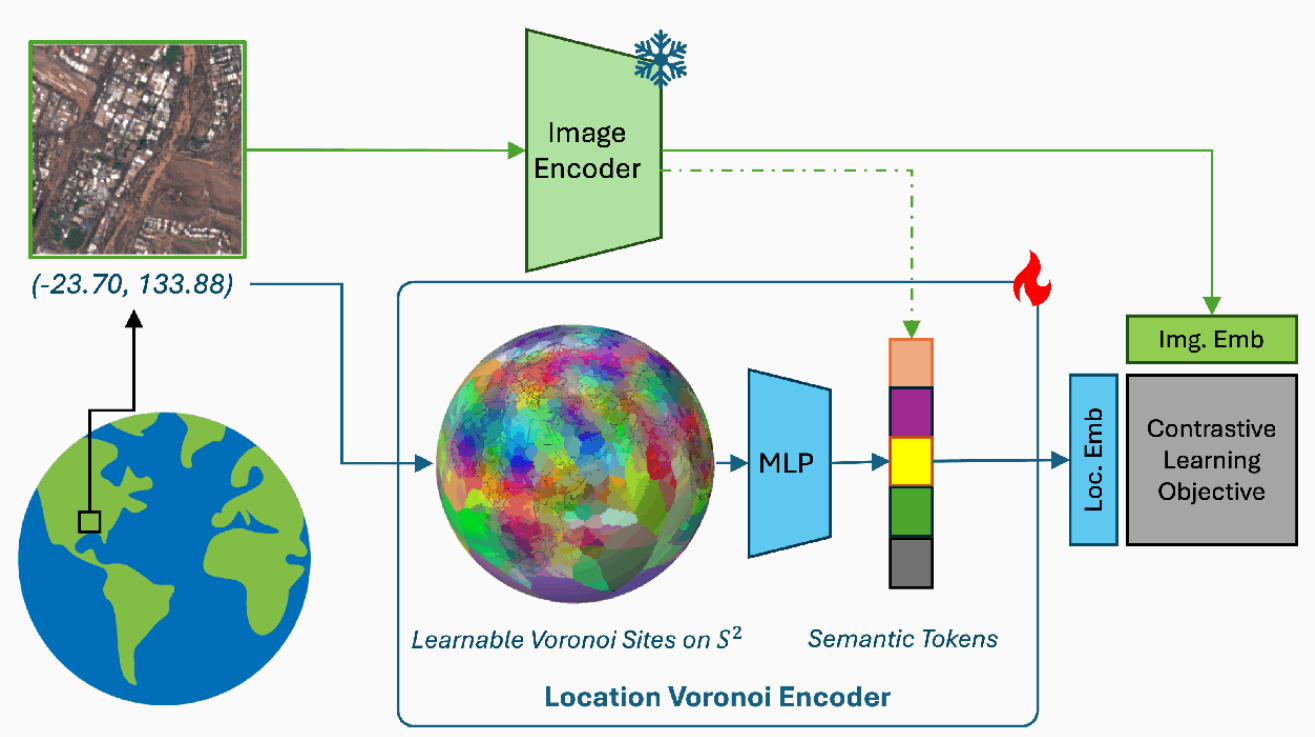


Figure 2. Overview of TTE [2].
Source: TTE [2], ECCV 2026.

그림의 아래 경로는 좌표를 지역 특징으로 바꾸고, 여러 지역이 함께 사용하는 token을 참고한다. 위 경로는 고정한 영상 encoder에서 학습 신호를 얻는다. 좌표·영상 특징의 대조학습과 함께, token이 영상 특징을 복원하고 좌표의 token 선택이 영상의 선택과 맞도록 학습한다. 새 과제에서는 아래 좌표 경로만 사용한다.

SLED [3]. 관측 모델이 이미 배운 특징을 좌표 모델에 직접 전달한다. 고정한 teacher가 위치 c에서 제공하는 특징을 $e_t(c)$라 하면, 학생의 좌표 특징 $z_\theta(c)$를 선형 head W_t로 teacher의 차원에 맞춘다. 관측된 위치와 teacher 쌍에 대한 복원을 기본 형태로 쓰면 다음과 같다.

$$\mathcal{L}_{\text{rec}} = \mathbb{E}_{(c,t)} \left\| W_t z_\theta(c) - e_t(c) \right\|_2^2 .$$

각 샘플은 좌표 encoder와 해당 관측의 teacher를 통과한다. 자료 종류가 늘어나면 teacher별 head를 추가하여 하나의 좌표 표현을 학습한다. 여러 센서 자료가 각 위치에 모두 있지 않아도, 관측된 좌표·teacher 쌍마다 복원 오차를 계산할 수 있다. 이후 예측에서는 좌표 특징과 새 과제의 라벨을 사용한다.

MIND [4]. 여러 teacher를 복원하되, 전체 특징뿐 아니라 앞쪽의 적은 차원으로도 모든 teacher 특징을 복원하게 한다. 그림의 위쪽에서는 하나의 좌표 encoder가 특징 z를 만들고, 앞 m개 차원인 $z_{1:m}$을 각 선형 head에 보낸다. Teacher는 위성영상·기후·사진·종 관측에서 배운 고정된 특징을 제공한다.

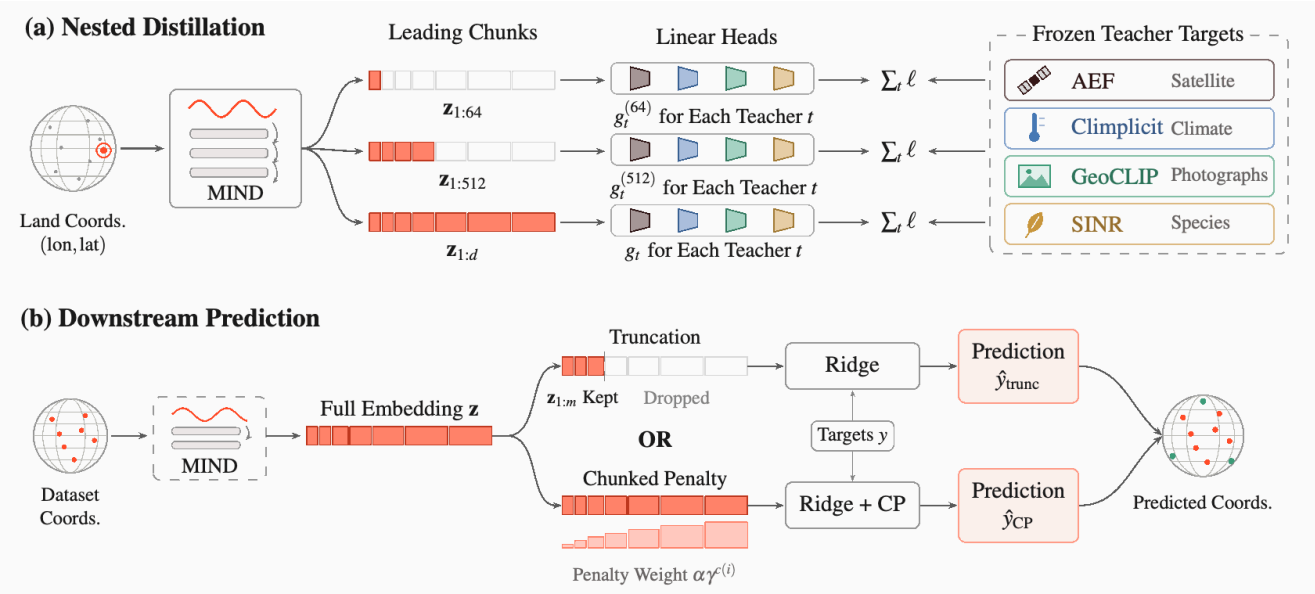


Figure 3. MIND [4] training and downstream prediction.

Source: MIND [4], arXiv 2026.

학습할 차원들을 $\mathcal{M}$이라 하면 원문의 full·prefix 손실을 다음과 같이 요약할 수 있다.

$$\mathcal{L}_{\text{MIND}} = \sum_{t} \sum_{m \in \mathcal{M}} w_m \, \ell\big(g_t^{(m)}(z_{1:m}), e_t\big).$$

각 $g_t^{(m)}$는 prefix에서 teacher t의 전체 특징을 복원하는 head이다. w_m은 차원별 손실 비중이고, ℓ은 정규화된 특징의 cosine 거리와 MSE를 계산한다. 예를 들어 앞 64개 차원으로도 teacher를 복원하고, 더 많은 차원을 붙였을 때도 같은 teacher를 복원하도록 학습한다.

학습 후에는 복원 head를 제거한다. 그림의 아래쪽처럼 앞쪽 차원만 남겨 ridge 예측기를 학습하거나, Chunked Penalty [4]로 뒤쪽 차원의 계수를 더 강하게 규제한다. 이 규제는 $\alpha \sum_i \gamma^{k(i)} \beta_i^2$ 형태이며, β_i는 예측기의 계수, $k(i)$는 해당 차원의 chunk 번호이다. $\gamma > 1$이면 뒤쪽 chunk를 사용할 때 더 큰 규제가 적용된다.

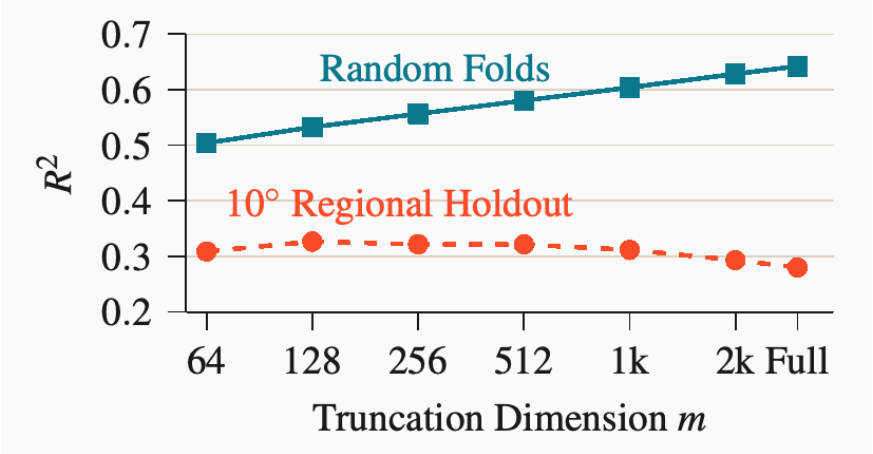


Figure 4. Chunk performance across different holdouts.

Source: MIND [4], arXiv 2026.

차원을 늘리면 무작위 분할 성능은 높아지지만, 지역 제외 평가에서는 같은 경향이 나타나지 않는다. 이 모델은 위치별 teacher 복원으로 표현을 만들고, 새 과제의 예측기에서 공간적 스케일을 조절한다.

3. Method

따라서 소수의 지원 위치에서 다른 질의 위치의 teacher 특징을 예측하도록 좌표 encoder를 학습하는 방법을 제안한다. 매 단계에서 라벨이 있다고 가정하는 지원 위치 S와 예측할 질의 위치 Q를 고른다. 가까운 위치와 떨어진 지역을 모두 포함하고, 지원 위치의 수도 바꾼다.

R2-D2 [5]와 같이 ridge regression을 미분 가능한 예측기로 사용한다. 두 집합의 좌표 특징을 Z_S, Z_Q로 모으면 지원 라벨을 질의 예측으로 바꾸는 행렬은 다음과 같다.

$$T_\theta = Z_Q Z_S^\top \left(Z_S Z_S^\top + \lambda I\right)^{-1}, \qquad \hat{y}_Q = T_\theta y_S.$$

T_θ는 지원 위치의 값에 적용할 예측 가중치이다. $\lambda > 0$는 ridge 규제의 크기이며, 절편을 생략한 식이다. 사전학습에서는 실제 라벨 대신 정규화해 합친 teacher 특징을 사용한다. 이를 지원·질의 위치에 모은 행렬을 Φ_S, Φ_Q라 하면 다음 손실로 좌표 encoder를 학습한다.

$$\mathcal{L}(\theta) = \mathbb{E}_{(S,Q)\sim\mathcal{P}} \left[\frac{\|T_\theta \Phi_S - \Phi_Q\|_F^2 + \sigma^2 \|T_\theta\|_F^2}{|Q|} \right].$$

첫 항은 지원 위치의 teacher 특징으로 질의 위치의 특징을 예측한 오차이다. 둘째 항은 지원 라벨의 잡음이 예측에서 크게 증폭되는 것을 줄인다. σ^2는 가정한 지원 라벨 잡음의 분산이고, $\mathcal{P}$는 지원 위치의 수와 배치를 정하는 분포이다.

지원·질의 위치를 고르고 T_θ를 계산한 뒤, 이 손실을 좌표 encoder까지 미분해 갱신한다. 학습을 마치면 encoder를 고정하고 실제 조사 라벨로 새 예측기를 학습한다.

4. Experiments

CoordBench [4]에서 표현을 고정하고 실제 라벨로 예측기를 학습한다. MIND [4]와 encoder·teacher·사전학습 자료·표현 차원을 맞춰 학습 목표를 비교한다. 기준선은 위치별 특징 복원과 MIND [4]이며, Chunked Penalty [4]를 적용한 설정도 함께 비교한다.

평가	비교할 내용	지표
무작위 분할	라벨이 있는 위치 주변의 예측	회귀 R^2, 분류 accuracy
지역 제외	라벨을 얻지 못한 다른 지역의 예측	회귀 R^2, 분류 accuracy
소수 라벨	지원 위치의 라벨 수를 줄였을 때의 변화	라벨 수별 성능

같은 지원 위치에서 아래 조건을 바꾸어 비교한다.

Ablation	비교할 내용
공간 분리 episode → 무작위 episode	지역을 나누어 예측하도록 학습한 효과
지원 위치 수 변경	적은 라벨에 맞춘 학습의 효과
$\sigma^2\|T_\theta\|_F^2$ 제거	잡음 항이 예측 안정성에 주는 효과

잡음 항은 회귀 지원 라벨에 같은 크기의 잡음을 넣고 비교한다. 최종적으로 소수 라벨의 지역 제외 성능과, 공간 episode를 바꾸었을 때의 차이를 함께 확인한다.

References

[1] K. Klemmer, E. Rolf, C. Robinson, L. Mackey, M. Rußwurm. *SatCLIP: Global, General-Purpose Location Embeddings with Satellite Imagery*. AAAI, 2025.

[2] D. Cher, H. Iqbal, E. Xing, B. Wei, N. Jacobs. *Tessellating the Earth: Learnable Spherical Voronoi Partitions for Location Encoding*. ECCV, 2026.

[3] K. Lane, Z. Wang, E. Rolf, M. Karimzadeh. *SLED: Scalable Location Encoding via Distillation*. arXiv:2608.06612v1, 2026.

[4] I. Corley et al. *MIND the Gap: A Geographic Implicit Neural Representation with Adjustable Spatial Scale*. arXiv:2609.25454v2, 2026.

[5] L. Bertinetto, J. F. Henriques, P. H. S. Torr, A. Vedaldi. *Meta-learning with Differentiable Closed-form Solvers*. ICLR, 2019.

Remote Sensing Dataset Generation

1. Introduction

위성영상으로 특정 관심 대상을 분할하려면, 그 대상이 찍힌 영상과 픽셀별 정답 mask가 필요하다. 위성영상은 하루에도 수십 TB가 생성이 되지만, 이는 라벨이 없는 이미지일 뿐더러, 실제 고해상도 위성영상은 거액의 돈을 주고 구매해야 하기 때문에, 위성영상 분석 연구에 있어서 가장 큰 병목은 정답 데이터가 있는 데이터셋의 수 이다. 생성 모델은 이렇게 부족한 영상-mask 쌍을 보충하는 데 사용된다. 중요한 것은 생성 영상이 자연스러울뿐 아니라, 이를 학습에 추가했을 때 실제 영상의 분할 성능이 좋아지는지이다.

이때 광학 위성영상은 RGB 사진과 다른 정보를 갖는다. 다중분광 영상(MSI)은 가시광선과 적외선 등의 여러 파장 구간을 측정하고, 초분광 영상(HSI)은 더 좁고 연속적인 구간을 측정한다. 한 픽셀에 여러 밴드(대략 200개)의 값이 들어 있으며, 이 값들의 관계가 재질을 구분하는 단서가 된다. 아래 NASA EMIT [1] 영상의 앞면은 지표의 실제 색을, 옆면은 위치별 파장 정보를 보여 준다.

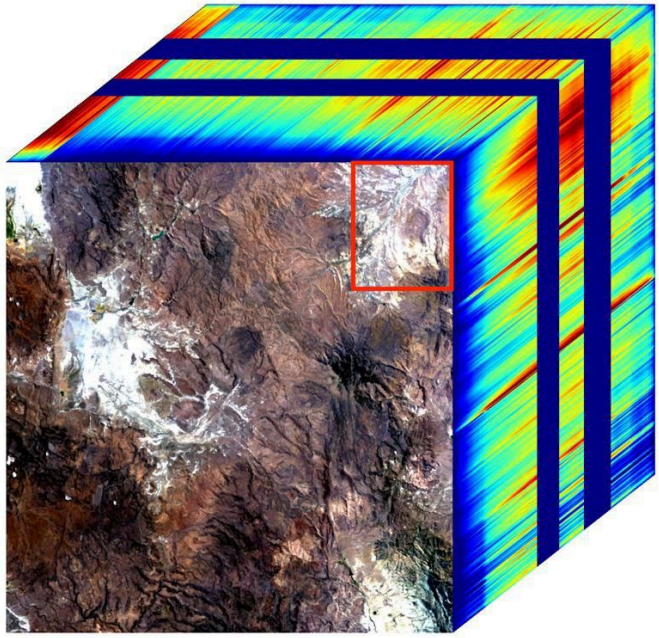


Figure 1. The side panels depict the spectral fingerprint for every point in the image.
Source: NASA/JPL-Caltech/USGS [1], 2022.

따라서 분광 학습 자료를 만들 때는 공간 구조, 밴드 사이의 관계, 정답 mask가 함께 맞아야 한다. Few-shot segmentation(FSS)은 소수의 영상-mask 예시인 support로 새 클래스의 다른 영상을 분할한다.

2. Related Work

Tackling Few-Shot Segmentation [2]. 이전에 공동저자로 참여한 연구로, 소수의 새 클래스 예시를 이용해 RGB 원격탐사 영상의 학습 자료를 늘렸다. 배경에서 생성할 영역을 정하고, support 객체 이미지를 조건으로 inpainting diffusion을 수행한다. 생성 객체와 예시의 feature를 cosine similarity로 비교해 유사도가 낮으면 다시 생성한다. 이어 사전학습 분할모델로 객체 경계에 맞는 mask를 얻는다.

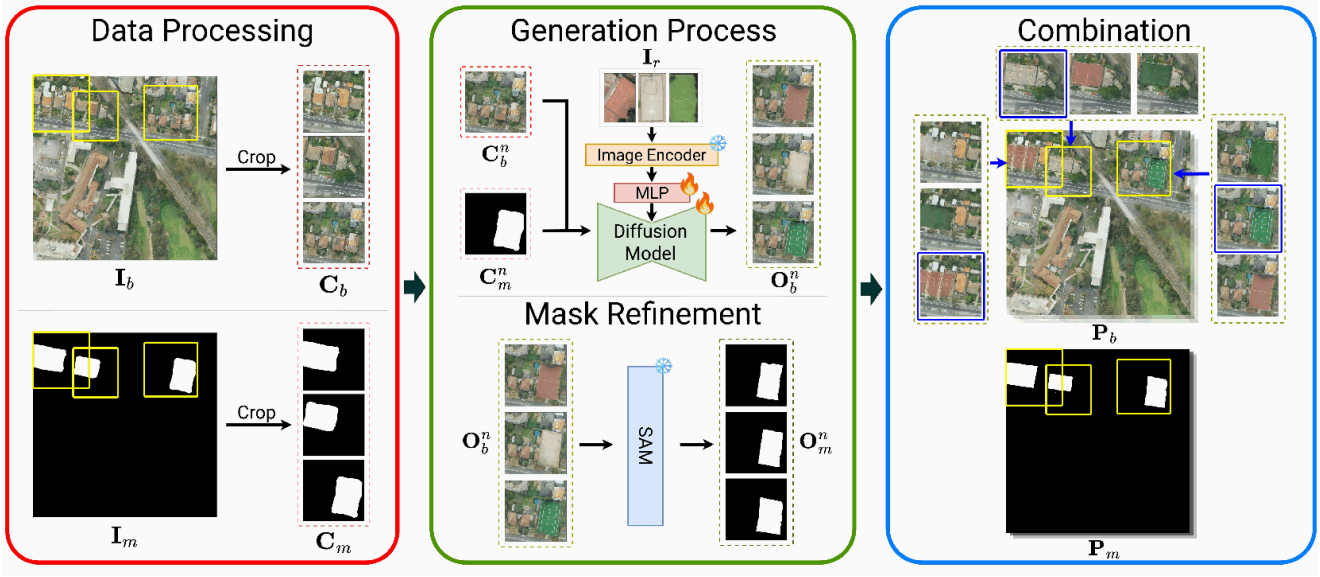


Figure 2. Overall pipeline of the proposed approach.

Source: Tackling Few-Shot Segmentation [2], ICLR ML4RS Workshop 2025.

그림에서 생성과 mask 보정은 서로 다른 단계다. 이렇게 얻은 영상-mask 쌍과 실제 소수 자료로 일반 분할모델을 fine-tuning한다. 새 클래스의 예시를 데이터 증강에 쓰는 접근이며, 생성 대상은 RGB 영상이다.

SpecDM [3]. 분광 영상과 mask를 함께 생성하기 위해 두 자료를 별도의 VAE로 압축한다. 영상 latent와 mask latent를 채널 방향으로 합쳐 diffusion을 학습하고, 생성한 공동 latent를 나눠 각각 복원한다. 원문 구조를 공통 기호로 쓰면 다음과 같다.

$$\begin{aligned} U &= \mathrm{cat}\big(E_X(X), E_Y(Y)\big), \qquad \tilde{U} \sim p_\theta(U), \\ (\tilde{X}, \tilde{Y}) &= \big(D_X(\tilde{U}_X), D_Y(\tilde{U}_Y)\big). \end{aligned} \tag{1}$$

E와 D는 encoder와 decoder다. 그림 3(a)는 공동 생성, (b)는 생성 자료를 실제 학습 자료에 추가하는 과정이다. 영상 VAE에는 spectral-angle 손실을 사용해 압축 과정의 분광 형태를 보존한다.

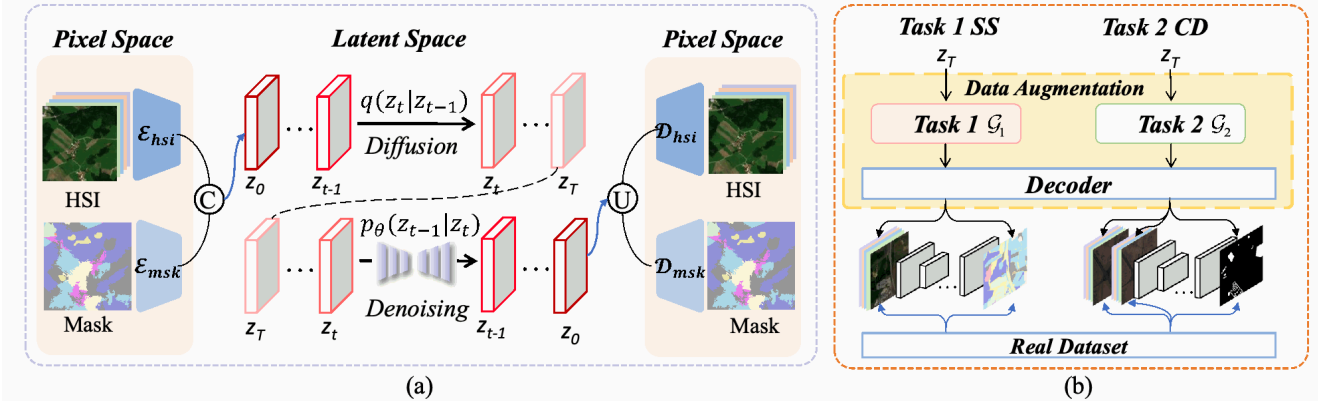


Figure 3. Overview of our approach.

Source: SpecDM [3], arXiv 2025.

RDF-MIG [4]. 다중분광 영상과 mask를 공동 생성하고, 학습 자료의 잡음이 생성 결과에 미치는 영향을 줄였다. 분할 설정에서는 RGB 밴드와 나머지 밴드를 각각 압축한 뒤, 두 표현과 mask를 3채널로 묶는다. 이 구성은 RGB 사전학습 diffusion과도 호환되며, 별도의 decoder가 생성한 표현을 다중분광 영상으로 복원한다. 원문의 실험에는 DDPM을 사용한다.

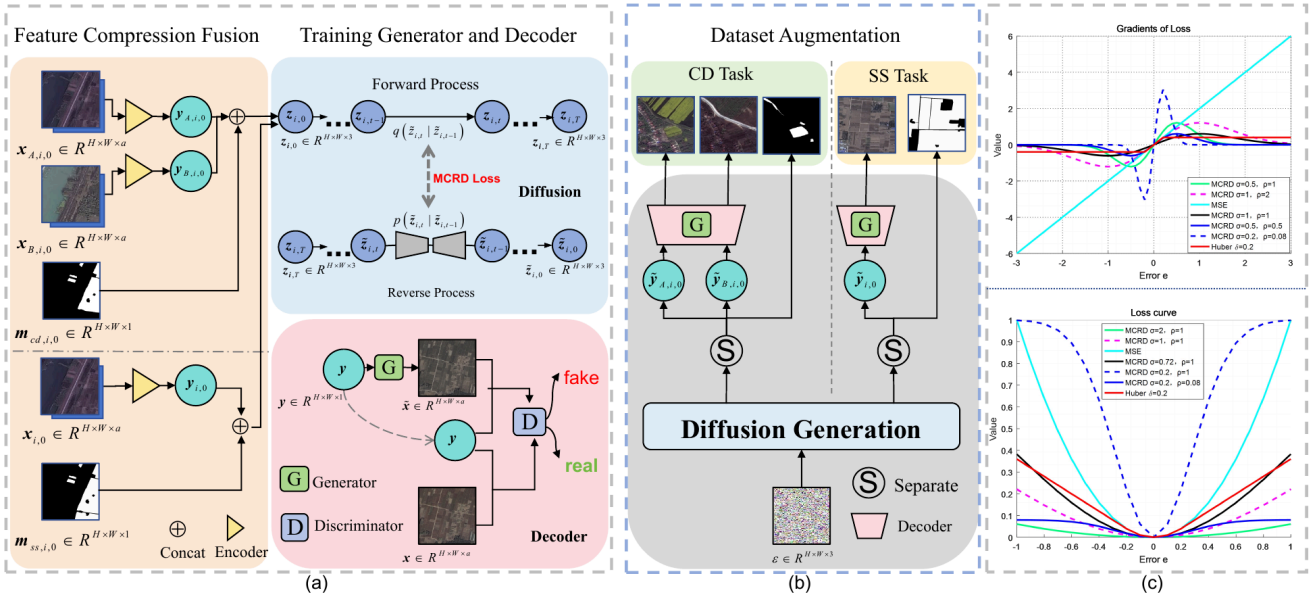


Figure 4. Method Workflow.

Source: RDF-MIG [4], CVPR 2026.

그림 4(a)는 압축·공동 생성·복원 학습이고, (b)는 생성 자료로 분할 또는 변화탐지 모델을 학습하는 과정이다. 오른쪽 (c)는 제안한 MCRD 손실이 큰 예측 오차의 영향을 줄이는 모습을 보여 준다. 공동 생성에 더해 잡음에 대한 강건성을 다루지만, 이 실험의 중심은 소수 support로 학습하지 않은 클래스를 생성하는 설정은 아니다.

HyperSAM [5]. 관측한 MSI에서 같은 장면의 HSI를 합성한다. Generator가 재질의 혼합비 $a(u)$와 illumination $\ell(u)$를 추정하고, 같은 재질끼리 대응시킨 MSI·HSI library를 적용한다.

$$\hat{x}_{\mathrm{MSI}}(u) = \ell(u) A_{\mathrm{MSI}} a(u), \qquad \tilde{x}_{\mathrm{HSI}}(u) = \ell(u) A_{\mathrm{HSI}} a(u). \tag{2}$$

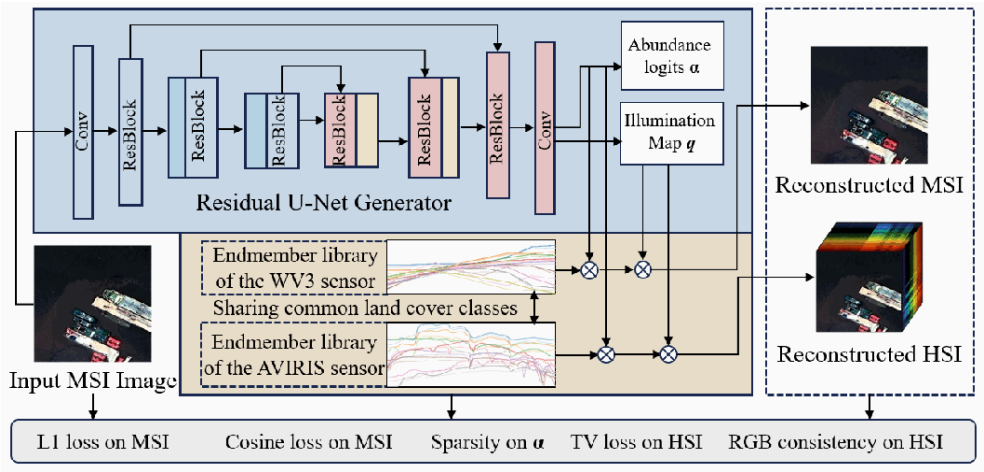


Figure 5. Physics-informed hyperspectral reconstruction pipeline.

Source: HyperSAM [5], arXiv 2026.

위쪽 경로는 입력 MSI를 복원하고, 아래쪽 경로는 같은 공간 구성의 HSI를 만든다. 정렬된 RGB에서 얻은 pseudo-mask를 합성 HSI와 짝지어 학습 자료로 사용한다. 새 장면의 형상을 만드는 과정과는 달리, 관측 장면의 분광 정보를 확장하는 방식이다.

위 연구들에서 소수 예시를 이용한 RGB 증강, 분광 영상-mask의 공동 생성, 관측 영상의 분광 확장은 서로 다른 설정으로 다뤄졌다.

3. Method

SpecDM [3]과 RDF-MIG [4]는 분광 영상과 mask를 함께 만드는 구조를 보여 준다. 여기서 더 확인하려는 것은, 분할 대상으로 학습하지 않은 클래스도 소수 예시만 보고 학습 자료를 만들 수 있는가이다. 이를 위해 support의 분광 특성과 공간 구조를 조건으로 넣는 공동 생성 방법을 제안한다. 입력은 같은 센서의 10밴드 영상 X_k와 관심 클래스의 이진 mask Y_k이고, 출력은 새 영상과 그에 대응하는 mask다. 기저 곡선이나 센서 변환은 우선 제외하고, 같은 밴드에서 소수 예시를 활용하는 문제부터 다룬다.

Support encoding. 전경과 배경의 밴드별 평균은 객체의 분광 특성을 전달한다. 여기에 모든 밴드를 받는 작은 CNN의 feature와 mask를 결합한 공간 token을 더해, 평균만으로 알기 어려운 모양과 주변 배치를 전달한다. 전경과 배경이 함께 있는 예시를 사용하고, $m_{k,\mathrm{fg}} = Y_k$, $m_{k,\mathrm{bg}} = 1 - Y_k$로 둔다.

$$
\begin{aligned}
\mu_{k,a} &= \frac{\sum_u m_{k,a}(u) X_k(u)}{\sum_u m_{k,a}(u)}, \qquad a \in \{\mathrm{fg}, \mathrm{bg}\}, \\
g_k &= \mathrm{MLP}([\mu_{k,\mathrm{fg}}; \mu_{k,\mathrm{bg}}]), \\
S_k &= \mathrm{Token}([H_\psi(X_k); \mathrm{Down}(Y_k)]), \qquad C_c = \{g_k, S_k\}_{k=1}^{K}.
\end{aligned}
\tag{3}
$$

u는 픽셀 위치이고, H_ψ는 CNN이다. Down은 mask를 feature와 같은 격자로 줄인다. 공간 token에는 위치 정보를 더하고, K개 예시의 token을 생성기에 함께 전달한다.

Joint generation. SpecDM [3]처럼 영상과 mask에 별도의 VAE를 두고, 같은 크기의 latent를 채널 방향으로 합친다. 하나의 U-Net이 이 공동 latent를 생성하면서 cross-attention으로 C_c를 받는다. 초기 구현은 conditional flow matching [6]을 사용한다. 같은 클래스의 support와 다른 목표 patch (X_q, Y_q)를 한 묶음으로 학습하며, 잡음 U_0에서 목표 latent U_1로 가는 방향을 예측한다.

$$
\begin{aligned}
U_1 &= \mathrm{cat}(E_X(X_q), E_Y(Y_q)), \qquad U_0 \sim \mathcal{N}(0, I), \\
U_t &= (1 - t) U_0 + t U_1, \qquad t \sim \mathcal{U}(0, 1), \\
\mathcal{L} &= \mathbb{E}\left[\| v_\theta(U_t, t, C_c) - (U_1 - U_0) \|^2 \right].
\end{aligned}
\tag{4}
$$

생성할 때는 새 잡음에서 출발해 v_θ를 따라 공동 latent를 만들고, 이를 나누어 두 decoder로 영상과 mask를 얻는다. 영상과 mask가 같은 공간 표현을 사용하도록 하는 설계이며, 두 출력의 정합은 실험으로 확인한다. 영상 VAE의 분광 재구성 손실은 기존 구조를 사용한다. 자료의 반사율 스케일을 확인해 출력 범위를 맞추고, 밴드별 분포가 실제 자료와 얼마나 달라지는지도 살펴본다.

Base-to-novel transfer. VAE, support encoder, 생성기는 base 클래스 자료에서 학습한다. 공동 생성 학습에는 모든 픽셀의 라벨이 유효한 patch를 사용하며, 미표기 픽셀을 배경으로 바꾸지 않는다. 새 클래스에서는 $K = 1, 5$개 support만 넣고 모델을 고정한 채 생성한다. 전체 클래스로 학습한 공개 생성기나 mask VAE를 그대로 가져오지는 않는다. 제안의 초점은 소수 support의 조건을 만들고, 그 조건에서 새로운 클래스의 영상과 mask를 생성하도록 학습하는 데 있다.

4. Experiments

Benchmark and Comparison

주 실험은 Sentinel-2의 10밴드 토지피복 분할 자료인 SegMunich [7]로 진행한다. 공개 ZIP에서 영상과 mask 9,846쌍을 확인했다. 표본 mask 3개에는 모든 픽셀에 라벨이 있었으며, 전체 자료의 유효 라벨과 클래스별 수를 확인한 뒤 학습용 base, 설정 선택용 validation, 최종 평가용 novel 클래스로 나눈다. 공개 분할을 그대로 few-shot 벤치마크로 부르지 않고, 클래스 분할과 사용 patch 목록을 별도로 정리한다.

기존에 고려한 HyRANK [8]는 Dioni와 Loukia에서 라벨이 있는 픽셀이 각각 약 5.8%, 5.7%였다. 확인한 16·32·64 크기에서는 모든 픽셀이 주석된 다중 클래스 patch가 없어, 이번 공동 생성의 첫 학습 자료에서는 제외한다. HSI 생성은 충분한 영상-mask 쌍을 확보한 뒤 확장한다.

모든 조건에 같은 base 학습 자료와 실제 support K개, 같은 test를 사용한다. Test는 생성기 학습이나 생성 결과 선택에 사용하지 않는다. 영상의 위치 정보와 중복·겹침을 확인해 support와 test를 분리하되, 위치 정보를 검증하지 못한 자료에서는 지역 간 일반화까지 주장하지 않는다. 생성량 N과 실제·생성 자료의 비율은 validation에서 정한다. `–`는 미측정 값이다.

조건	분할 방법	새 클래스에서 사용하는 자료	$K=1$ mIoU	$K=5$ mIoU
A	일반 분할	실제 K개로 head 학습	-	-
B	Few-shot segmentation	실제 K개로 prototype 구성	-	-
C	일반 분할	실제 K개와 생성 N개로 head 학습	-	-
D	Few-shot segmentation	실제 K개와 생성 N개로 prototype 구성	-	-

일반 분할은 base에서 학습한 backbone을 고정하고 새 클래스의 head를 학습한다. FSS는 base에서 학습한 encoder를 고정하고 support의 전경·배경 feature 평균인 prototype으로 분할한다. A와 C의 head 학습 횟수도 맞춘다. **C-A와 D-B가 생성 자료의 직접적인 효과**이고, C-B와 D-C는 자료를 활용하는 분할 방식의 비교다. Support를 여러 번 추출해 실제 novel-class mIoU의 평균과 편차를 보고한다. 배경의 쉬운 픽셀이 점수를 높이지 않도록, 주 지표는 관심 클래스의 IoU를 novel 클래스에 걸쳐 평균낸 값으로 둔다.

Ablation

비교	확인할 내용	주 평가
분광 평균만 / 분광 평균+공간 token	Support의 모양 정보가 필요한가	실제 novel-class mIoU
영상·mask 독립 생성 / 공동 latent 생성	두 출력을 함께 만드는 효과가 있는가	mIoU, 영상-mask 정합
단순 복제·기본 변형 / 조건부 생성	예시를 반복하는 것 이상의 이점이 있는가	mIoU, 형상·배경 다양성
같은 support 조건의 diffusion / flow	효과가 생성 학습 방식에 따라 달라지는가	mIoU, 생성 시간

생성량은 같게 맞춘다. 구조 비교에는 SpecDM [3]과 RDF-MIG [4]에 같은 support 조건을 붙인 구현을 사용하고, 원형 모델을 그대로 재현한 결과와 구분한다. 실제 분할 성능을 중심으로, 클래스별 밴드 분포와 생성 mask의 경계가 영상의 분광 영역과 맞는지 함께 확인한다.

기대 결과. 같은 수의 실제 라벨에서 C가 A보다, 또는 D가 B보다 높은 성능을 보이는 것이다.

실패 가능성. Base와 새 클래스의 차이가 크면 예시를 제대로 반영하지 못하거나, 생성 영상과 mask가 어긋나 분할 성능이 떨어질 수 있다.

대안. 공동 생성의 정합이 문제라면 support mask를 먼저 고정하고 영상만 조건부 생성하는 방식부터 비교한다. 클래스별 자료가 부족하면 클래스 수를 줄인 예비 실험으로 조건 전달을 확인한 뒤 범위를 넓힌다.

References

[1] NASA/JPL-Caltech/USGS. *NASA's EMIT Generates Image Cube of Surface Minerals in Northwest Nevada*. NASA, 2022.

[2] S. A. Immanuel, W. Cho, J. Heo, D. Kwon. *Tackling Few-Shot Segmentation in Remote Sensing via Inpainting Diffusion Model*. ICLR ML4RS Workshop, 2025. arXiv:2503.03785v1.

[3] W. Liu et al. *SpecDM: Hyperspectral Dataset Synthesis with Pixel-level Semantic Annotations*. arXiv:2502.17056v1, 2025.

[4] Z. Cao, W. Wei, Q. Gao, Y. Fu. *RDF-MIG: A Robust Diffusion Framework for Masked Image Generation to Augment Semantic Segmentation and Change Detection*. CVPR, 2026.

[5] L. Pang et al. *HyperSAM: A Promptable Foundation Model for Hyperspectral Remote Sensing*. arXiv:2609.37340v1, 2026.

[6] Y. Lipman et al. *Flow Matching for Generative Modeling*. ICLR, 2023. arXiv:2210.02747v2.

[7] D. Hong et al. *SpectralGPT: Spectral Remote Sensing Foundation Model*. IEEE TPAMI, 2024. SegMunich data.

[8] K. Karantzalos et al. *HyRANK Hyperspectral Satellite Dataset I*. Zenodo, v001, 2018.